



DISRUPTIVE ARCHITECTURES: IOT, IOB & GENERATIVE IA

Enzo Ross Gallone – 551754 - 2TDSPM
Gabriel de Andrade Baltazar - 550870 – 2TDSPM
Leonardo Cordeiro Scotti – 550769 - 2TDSPM
Pedro Gomes Fernandes - 551480 - 2TDSPM
Vinícius de Araújo Camargo - 99494 - 2TDSPM

São Paulo, SP

2024

Documentação do Projeto de IA Generativa para Previsão de Tendências no Mercado de Tecnologia

Este documento fornece uma análise detalhada da arquitetura de IA utilizada no projeto, bem como uma descrição de como a IA foi implementada para prever tendências no mercado de tecnologia. O projeto foca na utilização de uma rede neural LSTM (Long Short-Term Memory) para gerar previsões sobre a popularidade de tópicos relacionados a Inteligência Artificial (IA) e Machine Learning (ML).

Arquitetura LSTM

A arquitetura escolhida para este projeto é a LSTM, uma variação das redes neurais recorrentes (RNNs). A LSTM é especialmente eficaz para lidar com dados temporais e sequenciais, o que a torna ideal para a previsão de séries temporais.

Características da LSTM

A LSTM pode reter informações por períodos mais longos devido às suas unidades de memória, o que é crucial para capturar padrões em dados temporais.

Possui mecanismos de portas (entrada, esquecimento e saída) que ajudam a controlar a quantidade de informação a ser mantida ou descartada, evitando o problema de desvanecimento do gradiente.

Justificativa da Escolha da Arquitetura

A escolha da LSTM para este projeto foi baseada em suas vantagens na modelagem de séries temporais e dados sequenciais. Em comparação com outras arquiteturas de RNNs, as LSTMs são mais capazes de lidar com dependências temporais longas e complexas, o que é essencial para prever tendências de popularidade ao longo do tempo.

Implementação da Arquitetura

Estrutura do Modelo

O modelo é composto por duas camadas LSTM sequenciais. A primeira camada LSTM é configurada para retornar uma sequência completa de saídas para que a próxima camada LSTM possa processá-las. A segunda camada LSTM processa essas saídas e extrai características temporais

Após as camadas LSTM, uma camada densa é usada para gerar a previsão final. Esta camada tem uma única unidade de saída, representando a previsão da popularidade.

Treinamento do Modelo

O modelo é treinado com dados escalados e transformados para capturar padrões temporais em série. As entradas são organizadas em janelas temporais para que o modelo possa aprender a partir de múltiplas observações anteriores.

O modelo é treinado por um número fixo de épocas usando o otimizador 'adam' e a função de perda 'mean_squared_error', que é apropriada para problemas de regressão.

Base de Dados

A base de dados utilizada para o treinamento e teste do modelo contém informações sobre a popularidade de tópicos relacionados a IA e ML. As colunas incluem métricas como popularidade, pesquisas crescentes e tendências de popularidade.

Preparação dos Dados

Valores ausentes foram tratados por meio de preenchimento com o valor mais recente disponível, assegurando que o modelo fosse treinado com um conjunto de dados completo e consistente.

Variáveis categóricas foram convertidas em variáveis numéricas para serem compreendidas pela rede neural.

Os dados foram escalados para o intervalo $[0, 1]$ usando a técnica de normalização `MinMaxScaler`, o que ajuda a melhorar a convergência e o desempenho do modelo.

Divisão dos Dados

Os dados foram divididos em conjuntos de treinamento e teste. A divisão foi realizada de forma a garantir que o modelo fosse treinado em uma parte dos dados e validado em outra parte não vista, o que permite avaliar o desempenho do modelo em dados não conhecidos.

Conclusão

A implementação da arquitetura LSTM demonstrou ser adequada para prever tendências no mercado de tecnologia, fornecendo previsões de popularidade e insights valiosos sobre padrões de mercado. A escolha da LSTM foi justificada pela sua capacidade de lidar com dependências temporais e sequenciais, e a preparação adequada dos dados garantiu que o modelo fosse treinado e avaliado de maneira eficaz.